Sprint 3. 데이터 분석 및 활용

Part 1. 머신러닝 개론 및 평가지표

AI 모델링을 위한

ML 기본 개념

강사: 권구현 | rngus4656@gmail.com

Sprint 3 part1 목차

- 머신러닝 학습 / 데이터 전처리
- 트리기반 모델 DT / RF / XGB
- 분류 / 회귀모델 성능 평가
- (Appendix) 주성분 분석(PCA), K-means 클러스터링

학습 자료 colab 링크: https://colab.research.google.com/drive/13HHVq7eCVzDxXEa0CxjNbqU-3hGZPQDn?usp=sharing

S3 Part 1

머신러닝 학습 / 데이터 전처리

EDA 데이터 전처리와 학습 데이터 셋 분리

지도학습 vs 비지도학습 vs 강화학습

인공지능 학습 종류와 특징

✓ 지도 학습(Supervised Learning)

- **정답이 있는 데이터를 학습**하여 분류 / 회귀 문제를 예측하는 학습 방식
  - 분류 모델(Classification): 데이터의 **정해진 라벨을 학습**하여 어디에 해당하는지 예측하는 모델

    e.g.) 타이타닉 생존 여부, 붓꽃 품종 분류, 고객 이탈여부 등
  - 회귀 모델(Regression): 정해진 라벨이 아닌 **연속된 수치 값**을 예측하는 모델

    e.g.)상품 가격 예측, 매출 예상금액, 기온 예측 등

✓ 비지도 학습(Unsupervised Learning)

- 정답 라벨이 없는 데이터를 특정 패턴과 형태를 찾아 예상 패턴, 군집을 예측하는 학습 방식

e.g.) PCA, K-Means Clustering, GAN 등

✓ 강화 학습(Reinforcement Learning)

- 특정 알고리즘에 따라 정답에 대한 보상, 가중치를 부여 받으며 재학습하는 방식

e.g.) Agent, AlphaGo, 자율주행 등

모델의 성능 향상을 위해서는 고품질의 학습 데이터가 매우 중요함

학습 데이터 전처리 - EDA

EDA(Exploratory Data Analysis) | 탐색적 데이터 분석

✓ 데이터 특징 파악

- 데이터의 **전체적인 특징**을 펼쳐보며 미리 가늠하는 단계

e.g.) shape, info(), describe() 확인, ID/고유번호 등 식별자 유무 확인(데이터 누수)

✓ 이상치, 결측치 탐색 및 시각화 분석

- 이상치와 결측치 여부 등을 탐색하고 데이터 특징을 시각화하여 분석하는 단계

e.g.) isna(), duplicated() 확인, 상관관계 및 그래프 시각화

✓ Feature Engineering, 데이터 전처리

- 데이터를 **모델이 학습하기 좋은 조건으로 변환 / 인코딩** 하는 데이터 전처리 단계

e.g.) 이상치/결측치 처리, 칼럼 단위 변환, 새로운 칼럼 생성, One-Hot 인코딩, Standard Scaling 등

✓ Feature Selection 반복적 모델 개선 과정

- 과적합 방지, 데이터 해석력 향상을 위한 주요 변수 선택 (모델 학습 전, 후에 걸쳐 전반적으로 수행)

e.g.) Feature Importance, Permutation Importance, SHAP Value 등 주요 특성 파악 및 실험

학습 데이터 셋 분리

train / validation / test 데이터 셋

✓ train 데이터 셋

- 모델이 직접적으로 학습하는 데이터 셋, 정답을 예측하는 근거 데이터 셋

e.g.) 문제집을 학습하여 지식을 쌓는 과정

✓ validation 데이터 셋

- 학습된 모델의 성능을 검증하기 위한 일부 데이터 셋 (딥 러닝에서는 생략하는 경우가 많다.)

e.g.) 모의고사를 통한 현재 수준 검증

✓ test 데이터 셋

- 모델의 최종 성능을 평가하기 위한 데이터 셋

e.g.) 수능 시험을 통해 최종 결과 확인

✓ 데이터 셋 분리 주요 특징

- 반드시 인코딩, 스케일링 전에 미리 분리해준다. (fit_transform 함수때문)
- 나누는 비율은 8:2, 7:3 등 데이터에따라 적용, train - test를 먼저 나누고 필요시 다시 train - val 셋 분리
- 검증 성능이 지나치게 잘 나오는 경우 데이터 누수를 의심 해볼 수 있다.
- 훈련 데이터 셋과 검증 셋 성능을 비교하여 과적합 여부를 판단할 수 있다.

S3 Part 1

트리 기반 모델 DT / RF / XGB

EDA 데이터 전처리와 학습 데이터 셋 분리

의사 결정 나무 (DT)

Decision Tree

✓ **트리구조로 계속해서 질문을 나누는 모델**

- 데이터를 특정 기준값으로 반복적 이진 분할
- 지니 불순도(Gini Impurity)를 최소화 하는 방향으로 가지 분기
- 결과값에 대한 해석 출력이 가능함

장점

- 구조가 직관적이며 설명력이 높음
- 설명력이 필요한 기관에 적절 (금융, 의료, 법률 등)

단점

- 단순 트리 구조로 깊어질수록 과적합이 쉽게 발생
- 작은 데이터 변화에도 구조에 영향이 크게 미칠 수 있음

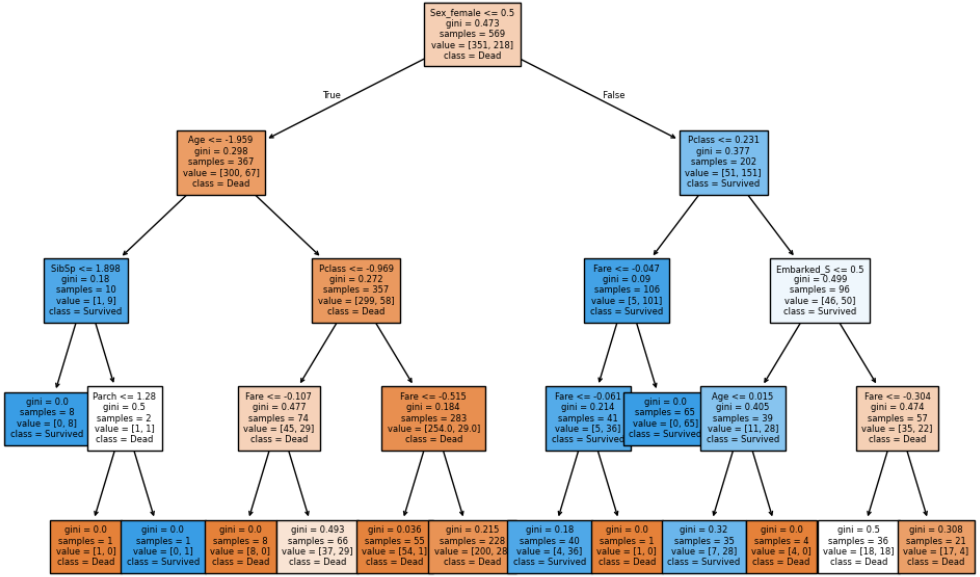

가장 기본적인 단일 트리구조 모델 Decision Tree

Random Forest

✓ **여러 개의 의사 결정 나무를 결합한 앙상블(Ensemble) 모델**

- 무작위 샘플링(Bootstrap Sampling)으로 여러 트리 모델 생성
- 각 트리의 예측 결과를 평균하여 예측 수행
- 단일 트리의 과적합 문제를 앙상블 구조로 완화한 모델

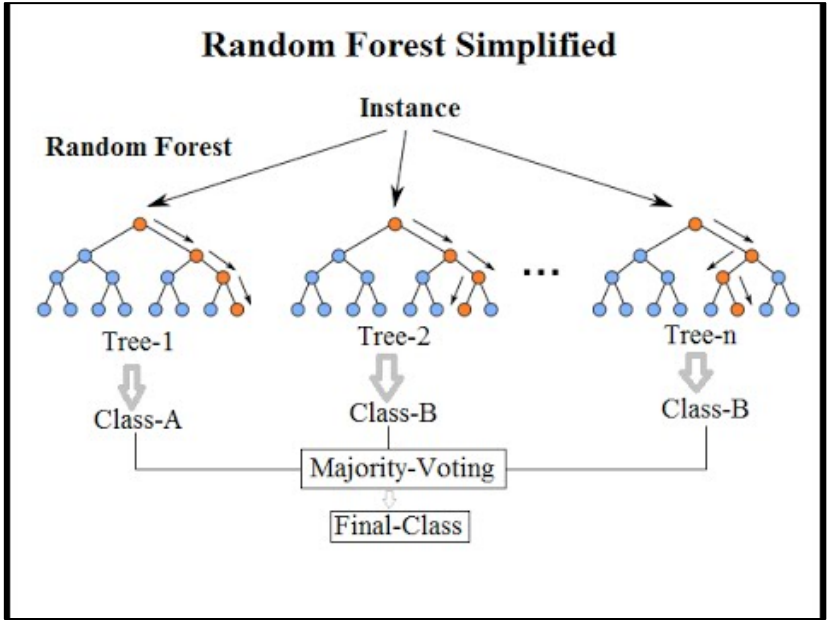

장점

- 단일 트리 모델 대비 과적합 위험 감소
- 대부분의 데이터 셋에서 안정적인 성능

단점

- 결과값에 대한 설명력이 부족할 수 있음 (블랙박스)

여러 묶음의 트리를 집계 Bootstrap Aggregating ➔ Bagging 기반 모델

XGBoost (Extreme Gradient Boosting)

XGBoost

✓ **이전 모델의 오답을 보완하며 학습하는 앙상블 모델**

- 이전 트리의 오차(잔차)를 보완하며 학습 진행 (Boosting)
- 점진적으로 오답을 줄여나가는 구조를 가지고 있음
- 병렬적 구조를 가진 RF와 달리 순차적인 구조를 가짐
- 기본적으로 Gradient Boosting모델을 확장한 모델

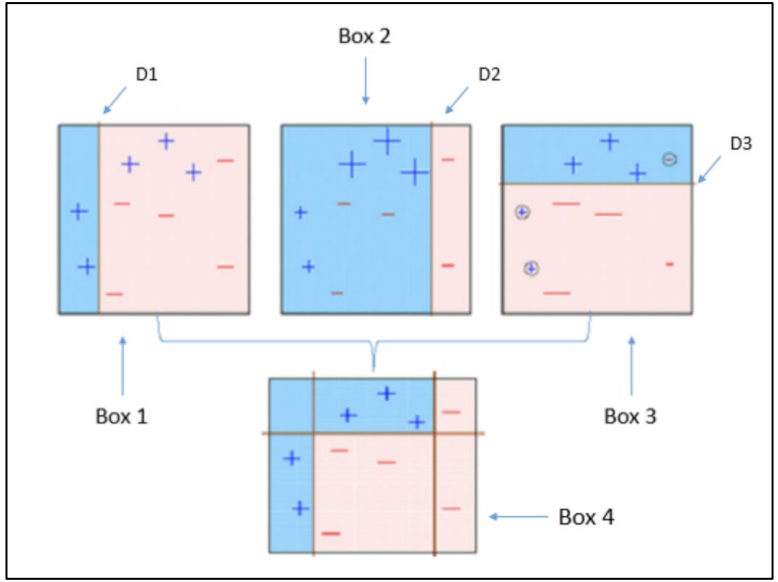

장점

- 연속형 수치데이터가 많은 회귀 문제에서 특히 좋은 성능
- 가중치 규제(L1, L2) 기능이 내장되어 안정적이며, 과적합이 적음

단점

- 모델이 가지고있는 하이퍼 파라미터가 복잡하여 튜닝이 어려움
- RF와 동일하게 블랙박스 성향을 가지며, 연산량이 더 증가함

이전 트리 모델을 점진적으로 보완 ➔ Boosting 기반 모델

S3 Part 1

분류 / 회귀 모델 성능 평가

분류모델과 회귀모델에서의 성능평가 기준

분류모델 성능평가 지표

Confusion Matrix (혼동 행렬)

✓ TP, FP, FN, TN (정답유무/예측한값)

- True Postive: 실제Positive를 Positive로 '잘' 예측한 경우 ➔ TP
- False Positive: 실제False를 Postive로 '잘못' 예측한 경우 ➔ FP
- False Negative: 실제 Postive를 Negative로 '잘못' 예측한 경우 ➔ FN
- True Negative: 실제 Negative를 Negative로 '잘' 예측한 경우 ➔ TN

✓ 정확도, 정밀도, 재현율, f-1 score

- Accuracy(정확도): 전체 중 맞춘 비율
- Precision(정밀도): 모델이 예측한 값이 정답인 비율
- Recall(재현율): 실제값 중 모델이 제대로 예측한 비율
- f1-score: Precision과 Recall의 조화 평균

		Predicted Class: Positive	Predicted Class: Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	**Sensitivity** $\frac{TP}{(TP+FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	**Specificity** $\frac{TN}{(TN+FP)}$
		Precision $\frac{TP}{(TP+FP)}$	**Negative Predictive Value** $\frac{TN}{(TN+FN)}$	**Accuracy** $\frac{TP+TN}{(TP+TN+FP+FN)}$

👉 Precision과 Recall은 trade-off 관계에 있다.

일반적으로 Recall 성능을 우선하여 F1-Score를 높이는 것을 기본적으로 한다.

회귀모델 성능평가 지표

MAE, RMSE, R2 Score

✓ MAE (Mean Absolute Error): 오차 절대값 평균

- 실제값과 예측값의 오차 절대값을 평균으로 함
- 음수가 섞여있을 경우 연산에 영향이 가지않도록 절대값을 사용
- 맨해튼(Manhattan) 거리라고도 불리우며 계단식 접근 방식

✓ RMSE (Root Mean Squared Error): 제곱 평균 오차의 제곱근

- 실제값과 예측값의 오차를 제곱하여 평균을낸 제곱근의 값
- 유클리디안(Euclidean) 거리라고도 불리우며 직선적 접근 방식
- 대부분의 회귀 모델에서 MAE보다 RMSE를 채택함

✓ R^2 Score (결정계수)

- 모델이 실제 데이터의 변동성을 얼마나 잘 설정하는지 나타내는 값
- 값의 범위는 0~1, 1에 가까울수록 데이터를 잘 설명

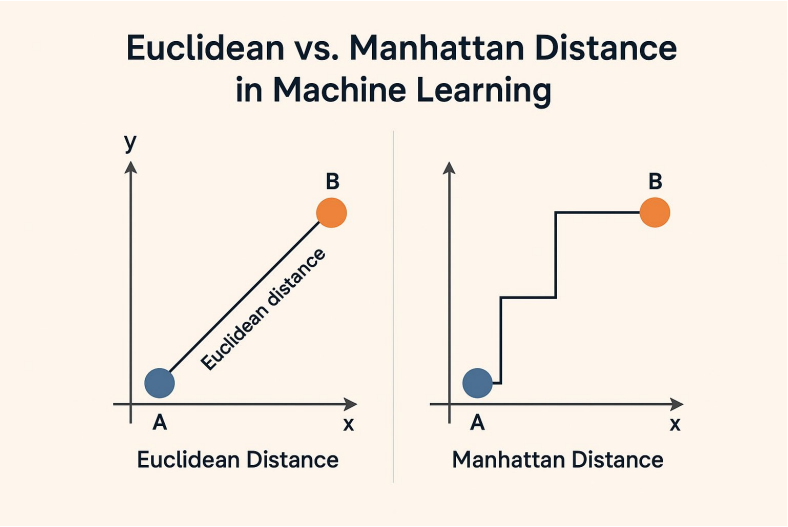

RMSE는 적을수록, R2는 1에 가까울수록 좋은 성능지표

학습모델의 변수 중요도

학습모델의 성능에 어떤 변수가 주요하게 작용했는지 확인하는 과정

✓ Feature Importance

- 트리 기반 모델의 불순도 감소량을 기준으로 계산되는 변수 중요도
- 여러 트리의 중요도를 평균하여 산출
- 연속형 변수나 범주 수가 많은 변수에 편향될 수 위험 있음

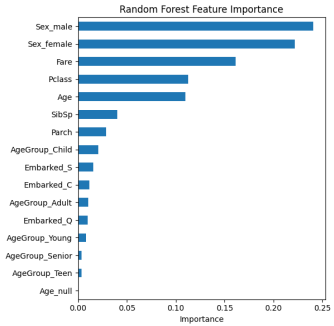

✓ Permutation Importance

- 특정 변수를 무작위로 섞었을 때 모델 성능 감소량으로 중요도 측정
- 모델 재학습 없이 계산 가능, Feature Importance보다 신뢰도가 높은편
- 변수 간 상관관계가 높으면 왜곡될 수 있음

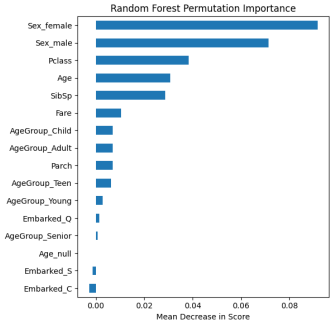

👉 변수 중요도를 확인하고 Feature Selection을 재시도하며 테스트 할 수 있다.

변수 중요도를 참고할 수는 있지만, 절대적인 신뢰는 위험

회고 및 Q&A

감사합니다.

Appendix

PCA, K-means Clustering

S3 Part 1

주성분 분석(PCA)
K-means 클러스터링

비지도 학습을 통한 차원축소 및 군집화

주성분 분석 PCA

Principal Component Analysis

✓ 고차원 데이터를 저차원으로 축소하는 기법

- 차원(칼럼)이 너무 많을때 차원축소를 위한 주성분 분석
- 데이터의 정보량을 최대한 보존
- 새로운 축(주성분)을 만들어 차원을 n개로 축소

✓ 사용 목적

- 주성분 시각화 목적
- 불필요한 노이즈 제거
- 모델 학습 속도 향상 및 변수간 상관성 완화

✓ 핵심 개념

- PC1 ➔ 가장 많은 분산을 설명하는 축, PC2, PC3 … 순
- 정보 손실을 최소화하면서 차원을 줄이는 방법

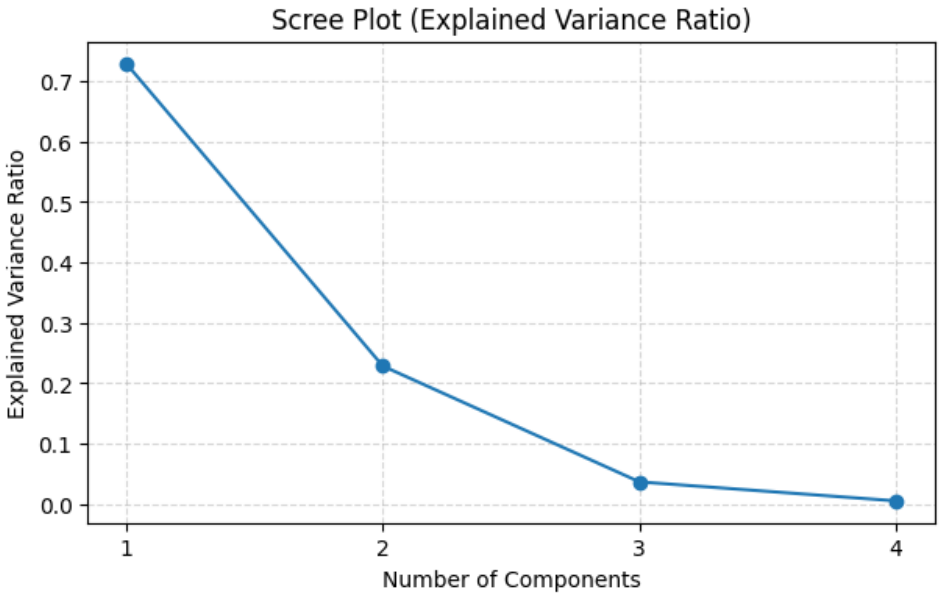

차원이 지나치게 많을때 (약 100개가량 이상) 사용할 수 있다.

K-means 클러스터링

비지도 학습 기반 군집화 기법

✓ 작동 원리

- k개의 중심점 초기화
- 각 데이터를 가장 가까운 중심에 배정
- 중심점 재계산 및 수렴할 때까지 반복

✓ 특징

- 단순하고 빠르게 군집화 분석 가능
- 거리 기반 알고리즘을 사용

✓ 핵심 개념

- 거리 기반으로 데이터를 군집화하는 기법

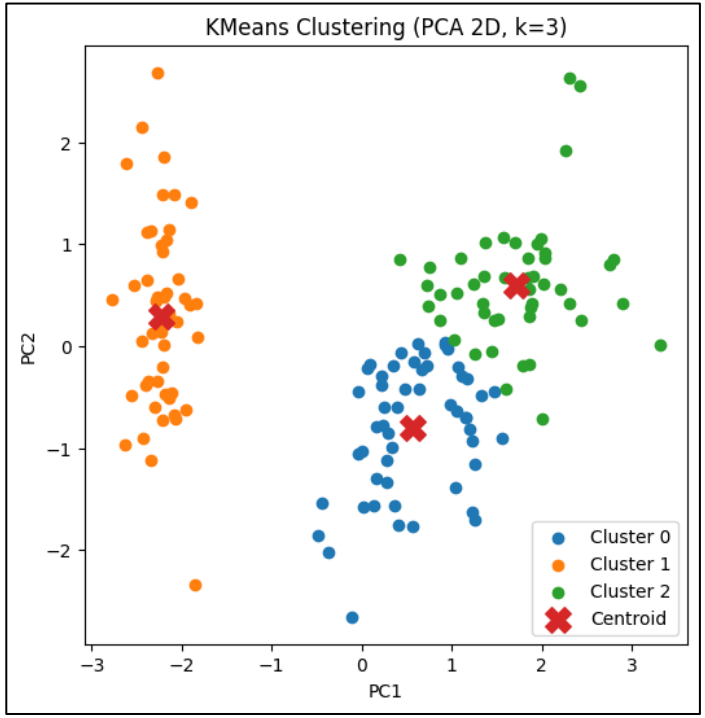

군집화를 통해 세그먼트 분석에 용이하게 사용 가능